GeekBrains, ML in Business

Lesson 7 Homework

Ссылки:

- Пример с Permutation Importance - https://www.kaggle.com/dansbecker/permutation-importance
- Github проекта SHAP - https://github.com/slundberg/shap
- https://arxiv.org/pdf/1809.04559.pdf
- https://medium.com/civis-analytics/demystifying-black-box-models-with-shap-value-analysis-3e20b536fc80
- https://en.wikipedia.org/wiki/Shapley_value

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd

import catboost as ctb
import category_encoders as ce
import shap

from sklearn.model_selection import train_test_split
from sklearn.base import BaseEstimator, TransformerMixin
from sklearn.preprocessing import OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline, FeatureUnion
from sklearn.metrics import recall_score, precision_score, roc_auc_score, accuracy_score, f1_score


# load JS visualization code to notebook
shap.initjs()
```

Классы и функции для задания

In [2]:
```
def evaluate_model(model, X_train, y_train, X_test, y_test):
    """
    Обучить и оценить модель.
    """
    model.fit(X_train, y_train, classifier__verbose=False)
    y_pred = model.predict(X_test)

    f1 = f1_score(y_test, y_pred)
    roc = roc_auc_score(y_test, y_pred)
    prec = precision_score(y_test, y_pred, average='binary')
    rec = recall_score(y_test, y_pred, average='binary')

    return (model, {'f1': [f1], 'roc-auc': [roc], 'precision': [prec], 'recall': [rec]})
```

Задание 1

Взять любой набор данных для бинарной классификации (можно скачать один из модельных с https://archive.ics.uci.edu/ml/datasets.php).

Решение Задания 1

Kaggle Dataset - HR Analytics: Job Change of Data Scientists:

- https://www.kaggle.com/arashnic/hr-analytics-job-change-of-data-scientists

In [3]:
```
df = pd.read_csv("data/aug_train.csv")
df.head()
```

Out[3]:

	enrollee_id	city	city_development_index	gender	relevent_experience	enrolled_university	education_level	major_discipline	experience	company_s
0	8949	city_103	0.920	Male	Has relevent experience	no_enrollment	Graduate	STEM	>20	N
1	29725	city_40	0.776	Male	No relevent experience	no_enrollment	Graduate	STEM	15	50-
2	11561	city_21	0.624	NaN	No relevent experience	Full time course	Graduate	STEM	5	N
3	33241	city_115	0.789	NaN	No relevent experience	NaN	Graduate	Business Degree	<1	N
4	666	city_162	0.767	Male	Has relevent experience	no_enrollment	Masters	STEM	>20	50-

Задание 2

Сделать обзорный анализ выбранного датасета.

Решение Задания 2

Посмотрим общие данные датасета.

In [4]:
```
df.shape
```

Out[4]:
```
(19158, 14)
```

In [5]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 19158 entries, 0 to 19157
Data columns (total 14 columns):
 #   Column                  Non-Null Count  Dtype  
---  ------                  --------------  -----  
 0   enrollee_id             19158 non-null  int64  
 1   city                    19158 non-null  object 
 2   city_development_index  19158 non-null  float64
 3   gender                  14650 non-null  object 
 4   relevent_experience     19158 non-null  object 
 5   enrolled_university     18772 non-null  object 
 6   education_level         18698 non-null  object 
 7   major_discipline        16345 non-null  object 
 8   experience              19093 non-null  object 
 9   company_size            13220 non-null  object 
 10  company_type            13018 non-null  object 
 11  last_new_job            18735 non-null  object 
 12  training_hours          19158 non-null  int64  
 13  target                  19158 non-null  float64
dtypes: float64(2), int64(2), object(10)
memory usage: 2.0+ MB
```

In [6]:
```
df.describe()
```

Out[6]:

	enrollee_id	city_development_index	training_hours	target
count	19158.000000	19158.000000	19158.000000	19158.000000
mean	16875.358179	0.828848	65.366896	0.249348
std	9616.292592	0.123362	60.058462	0.432647
min	1.000000	0.448000	1.000000	0.000000
25%	8554.250000	0.740000	23.000000	0.000000
50%	16982.500000	0.903000	47.000000	0.000000
75%	25169.750000	0.920000	88.000000	0.000000
max	33380.000000	0.949000	336.000000	1.000000

Нужно конвертировать таргет в int, так как у нас задача классификации, а не регрессии.

In [7]:
```
df['target'] = df['target'].astype(int)
```

Смотрим баланс таргета.

In [8]:
```
df['target'].value_counts()
```

Out[8]:
```
0    14381
1     4777
Name: target, dtype: int64
```

Есть заметный дисбаланс, но все не так плохо.

Посмотрим кардинальность категориальных (object) фичей.

In [9]:
```
for feat in df.select_dtypes('object').columns:
    print(f'Кардинальность {feat}: {df[feat].nunique()}')
```

```
Кардинальность city: 123
Кардинальность gender: 3
Кардинальность relevent_experience: 2
Кардинальность enrolled_university: 3
Кардинальность education_level: 5
Кардинальность major_discipline: 6
Кардинальность experience: 22
Кардинальность company_size: 8
Кардинальность company_type: 6
Кардинальность last_new_job: 6
```

Можно попробовать сделать one-hot encoding для признаков с кардинальностью < 10.

Посмотрим, какие категории есть у признака experience.

In [10]:
```
df['experience'].value_counts()
```

Out[10]:
```
>20    3286
5      1430
4      1403
3      1354
6      1216
2      1127
7      1028
10      985
9       980
8       802
15      686
11      664
14      586
1       549
<1      522
16      508
12      494
13      399
17      342
19      304
18      280
20      148
Name: experience, dtype: int64
```

Это просто кол-во лет опыта работы. Можно заменить ">20" на 21, "<1" на 0, получится вполне неплохо.

Признак city - явно просто города, в которых работают сотрудники. Чтобы закодировать этот признак, можно использовать CatBoostEncoder из библиотеки category_encoders.

Сделаем кодирование признаков в следующем задании.

Задание 3

Сделать feature engineering.

Решение Задания 3

Выберем числовые и категориальные признаки.

In [11]:
```
num_feats = df.select_dtypes('number').drop(columns='target').columns
```

In [12]:
```
cat_feats = df.select_dtypes('object').columns
```

Не будем брать ненужный признак enrollee_id - это просто числовой ID сотрудника.

In [13]:
```
num_feats = num_feats.drop('enrollee_id')
```

Заполняем пропуски с помощью SimpleImputer для всех категориальных признаков (на случай отсутствия будущих данных).

Заменяем все пропущенные значения категориальных признаков на самое частое значение (моду), числовых - на медиану.

In [14]:
```
num_imputer = Pipeline([
            ('imputer', SimpleImputer(strategy='median'))
        ])

cat_imputer = Pipeline([
            ('imputer', SimpleImputer(strategy='most_frequent'))
        ])

imputers = ColumnTransformer([
    ('num_imputer', num_imputer, num_feats),
    ('cat_imputer', cat_imputer, cat_feats),
])
```

Числовые признаки

Просто берем их как есть.

In [15]:
```
class NumberTaker(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        return self

    def transform(self, X):
        return X
```

In [16]:
```
num_transformer = Pipeline([
    ('nums', NumberTaker())
])
```

Энгодинг категориальных признаков

One-hot encoding для всех признаков, кроме experience, city (кардинальность < 10).

In [17]:
```
```

```
cat_transformer = Pipeline([
    ('ohe', OneHotEncoder(drop='first', sparse=False))
])
```

Трансформер кодирования признака experience.

In [18]:
```
class ExperienceTransformer(BaseEstimator, TransformerMixin):
    def __init__(self, column_name):
        self.column_name = column_name

    def fit(self, X, y=None):
        return self

    def transform(self, X):  # , y=None
        X = X.copy()
        X.loc[X[self.column_name] == '<1', self.column_name] = 0
        X.loc[X[self.column_name] == '>20', self.column_name] = 21
        X = X.astype(int)
        return X
```

In [19]:
```
experience_transformer = Pipeline([
    ('experience_transform', ExperienceTransformer('experience'))
])
```

Кодируем признак city с помощью CatBoostEncoder.

In [20]:
```
city_transformer = Pipeline([
    ('city_transform', ce.cat_boost.CatBoostEncoder())
])
```

Собираем все трансформации в один пайплайн.

In [21]:
```
transformers = ColumnTransformer([
    ('num_transformer', num_transformer, num_feats),
    ('cat_transformer', cat_transformer, cat_feats.drop(['experience', 'city'])),
    ('experience_transformer', experience_transformer, ['experience']),
    ('city_transformer', city_transformer, ['city']),
])
```

Собираем вместе заполнение пропусков и трансформации.

SimpleImputer возвращает данные в numpy.ndarray, поэтому нужно снова создать датафрейм, чтобы выбирать по столбцам признаков.

In [22]:
```
class NumpyToDataFrame(BaseEstimator, TransformerMixin):
    def __init__(self, column_names):
        self.column_names = column_names

    def fit(self, X, y=None):
        return self

    def transform(self, X):
        return pd.DataFrame(X, columns=self.column_names)
```

In [23]:
```
preprocessing = Pipeline([
    ('imputers', imputers),
    ('numpy_to_df', NumpyToDataFrame(num_feats.tolist() + cat_feats.tolist())),
    ('transforms', transformers)
])
```

Задание 4

Обучить любой классификатор (какой вам нравится).

Решение Задания 4

Делим данные на трейн и тест.

In [24]:
```
X_train, X_test, y_train, y_test = train_test_split(df.drop(columns=['target']), df['target'], test_size=0.2, random_state=42)
```

In [25]:
```
pipeline = Pipeline([
    ('preprocessing', preprocessing),
    ('classifier', ctb.CatBoostClassifier()), # cat_features=['experience', 'city'])),
])
```

In [26]:
```
model, model_metrics = evaluate_model(pipeline,
                                      X_train,
                                      y_train,
                                      X_test,
                                      y_test)
```

In [27]:
```
metrics = pd.DataFrame(model_metrics)
```

In [28]:
```
metrics
```

Out[28]:

	f1	roc-auc	precision	recall
0	0.392129	0.6132	0.592357	0.293067

Задание 5

Разобраться с SHAP и построить важности признаков для:

1. Всего тестового набора данных (summary_plot - дать интерпретацию),
2. Для топ 10%,
3. Для отдельных наблюдений вывести force_plot и попытаться проинтерпретировать результат.

shap не поддерживает sklearn Pipeline, поэтому обработаем данные отдельно, чтобы подать их в SHAP Explainer.

In [29]:
```
class DataProcessor:
    def __init__(self):
        self.data_imputers = ColumnTransformer([
            ('num_imputer', num_imputer, num_feats),
            ('cat_imputer', cat_imputer, cat_feats),
        ])
        self.city_ctb_encoder = ce.cat_boost.CatBoostEncoder(return_df=True)
        self.ohe_encoder = OneHotEncoder(drop='first', sparse=False)

    def fit(self, X, y=None):
        # Imputers
        self.data_imputers.fit(X, y)
        # Encode city
        self.city_ctb_encoder.fit(X['city'], y)
        # One-hot encoder
        self.ohe_encoder.fit(X[cat_feats.drop(['experience', 'city'])], y)

        return self

    def transform(self, X, y=None):
        X_trans = X.drop(columns=['enrollee_id'])
        # Imputers
        X_trans = pd.DataFrame(self.data_imputers.transform(X), columns=num_feats.tolist() + cat_feats.tolist())
        # Put numeric columns back to numeric
        X_trans[['city_development_index',
                 'training_hours']] = X_trans[['city_development_index', 'training_hours']].astype(float)
        # Encode experience
        X_trans.loc[X_trans['experience'] == '<1', 'experience'] = 0
        X_trans.loc[X_trans['experience'] == '>20', 'experience'] = 21
        X_trans['experience'] = X_trans['experience'].astype(int)
        # Encode city
        X_trans['city'] = self.city_ctb_encoder.transform(X_trans['city'])
        # One-hot for low-cardinality features
        X_trans = pd.get_dummies(X_trans, drop_first=True)
#         ohe_feats = cat_feats.drop(['experience', 'city']).tolist()
#         X_trans = pd.concat([
#             X_trans.drop(columns=ohe_feats),
#             pd.DataFrame(self.ohe_encoder.transform(X_trans[ohe_feats])),
#         ], axis=1)

        return X_trans

    def fit_transform(self, X, y=None):
        return self.fit(X, y).transform(X)
```

In [30]:
```
shap_data_processor = DataProcessor().fit(X_train, y_train)
X_test_trans = shap_data_processor.transform(X_test)
```

In [31]:
```
X_test_trans.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3832 entries, 0 to 3831
Data columns (total 35 columns):
 #   Column                                          Non-Null Count  Dtype  
---  ------                                          --------------  -----  
 0   city_development_index                          3832 non-null   float64
 1   training_hours                                  3832 non-null   float64
 2   city                                            3832 non-null   float64
 3   experience                                      3832 non-null   int32  
 4   gender_Male                                     3832 non-null   uint8  
 5   gender_Other                                    3832 non-null   uint8  
 6   relevent_experience_No relevent experience      3832 non-null   uint8  
 7   enrolled_university_Part time course            3832 non-null   uint8  
 8   enrolled_university_no_enrollment               3832 non-null   uint8  
 9   education_level_High School                     3832 non-null   uint8  
 10  education_level_Masters                         3832 non-null   uint8  
 11  education_level_Phd                             3832 non-null   uint8  
 12  education_level_Primary School                  3832 non-null   uint8  
 13  major_discipline_Business Degree                3832 non-null   uint8  
```

```
 14  major_discipline_Humanities              3832 non-null   uint8
 15  major_discipline_No Major                3832 non-null   uint8
 16  major_discipline_Other                   3832 non-null   uint8
 17  major_discipline_STEM                    3832 non-null   uint8
 18  company_size_100-500                     3832 non-null   uint8
 19  company_size_1000-4999                   3832 non-null   uint8
 20  company_size_10000+                      3832 non-null   uint8
 21  company_size_50-99                       3832 non-null   uint8
 22  company_size_500-999                     3832 non-null   uint8
 23  company_size_5000-9999                   3832 non-null   uint8
 24  company_size_<10                         3832 non-null   uint8
 25  company_type_Funded Startup              3832 non-null   uint8
 26  company_type_NGO                         3832 non-null   uint8
 27  company_type_Other                       3832 non-null   uint8
 28  company_type_Public Sector               3832 non-null   uint8
 29  company_type_Pvt Ltd                     3832 non-null   uint8
 30  last_new_job_2                           3832 non-null   uint8
 31  last_new_job_3                           3832 non-null   uint8
 32  last_new_job_4                           3832 non-null   uint8
 33  last_new_job_>4                          3832 non-null   uint8
 34  last_new_job_never                       3832 non-null   uint8
dtypes: float64(3), int32(1), uint8(31)
memory usage: 220.9 KB
```

Решение Задания 5.1

Возьмем только 100 наблюдений, чтобы быстро посчитать SHAP, так как признаков 35 штук.

In [45]:
```
shap_data_sample = shap.utils.sample(X_test_trans, nsamples=100, random_state=0)
```

In [46]:
```
explainer = shap.KernelExplainer(pipeline.named_steps['classifier'].predict_proba, shap_data_sample)
shap_values = explainer.shap_values(shap_data_sample, silent=True)
```

Значимость признаков.

In [47]:
```
shap.summary_plot(shap_values[0], shap_data_sample)
```

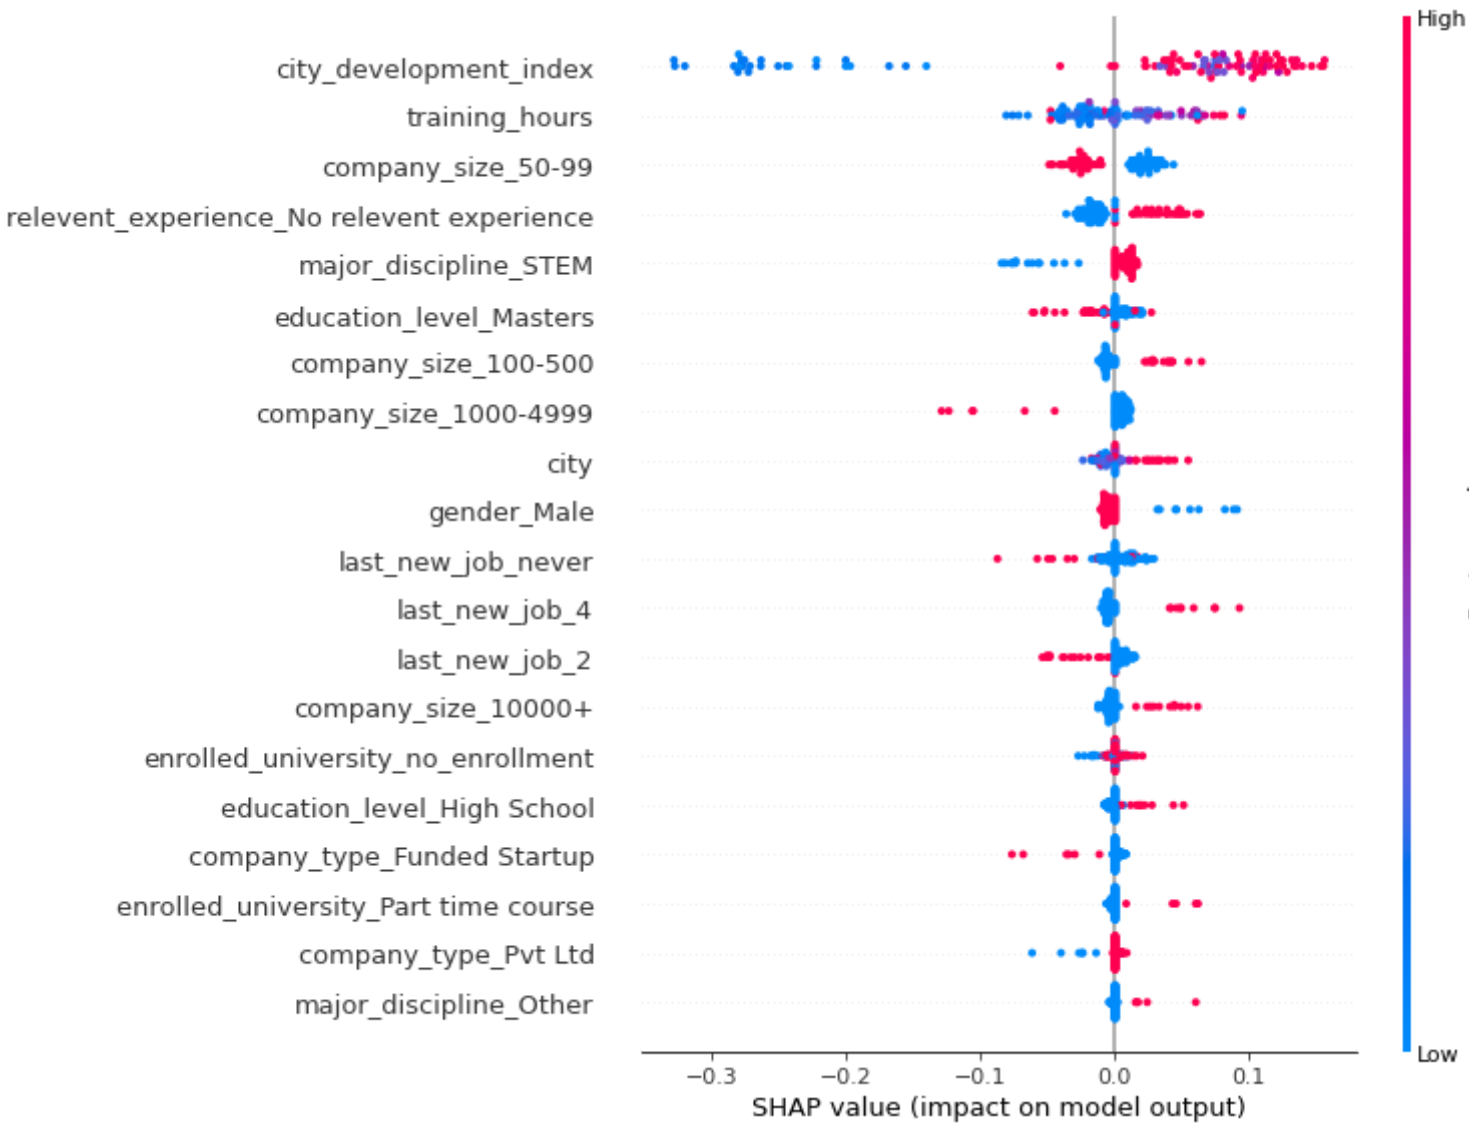

Можно заметить несколько вещей:

- Чем более развит город места работы, тем вероятнее дата саентисты будут в поисках новой работы.
- Дата саентисты, не имеющие релевантного опыта работы, более склонны к поиску новой работы.
- В компаниях с 50-99 сотрудниками дата саентисты скорее предпочтут остаться на своей работе, а в более больших компаниях (100-500, 10000+ сотрудников) будут чаще искать новую работу. Что интересно, за исключением некоторых выбросах, в компаниях с 1000-4999 сотрудников дата саентисты не имеют особого предпочтения.
- Выпускники не-STEM дисциплин обучения менее склонны к поиску новой работы.
- Специалисты, работающие на текущей должности ~2 года склонны остаться на текущем месте работы, а специалисты со стажем 4 года на текущем месте работы уже больше заинтересованы в поиске новой работы.

В целом, дата саентисты и специалисты технических профессий более склонны к поиску новой работы и задач, когда они уже достаточно знакомы с текущими задачами и у них появляется желание развиваться дальше, узнавать новые вещи.

Решение Задания 5.2

Найдем топ 10% признаков. Всего признаков 35, поэтому возьмем несколько больше - 5 признаков.

In [49]:
```
importance_df = pd.DataFrame({'importance': pipeline.named_steps['classifier'].get_feature_importance()},
                             index=X_test_trans.columns.tolist())
top_5_feats = importance_df.sort_values('importance', ascending=False).head(5)
top_5_feats
```

Out[49]:

	importance
city_development_index	25.960646
training_hours	11.897058
last_new_job_never	11.081841
company_size_1000-4999	9.163971
last_new_job_>4	8.917976

Самые важные 10 признаков.

In [50]:
```
top_cols = top_5_feats.index.tolist()
top_cols
```

Out[50]:
```
['city_development_index',
 'training_hours',
 'last_new_job_never',
 'company_size_1000-4999',
 'last_new_job_>4']
```

Решение Задания 5.3

In [106…
```
shap.force_plot(explainer.expected_value[1], shap_values[1][1], shap_data_sample.iloc[1, :])
```

Out[106…

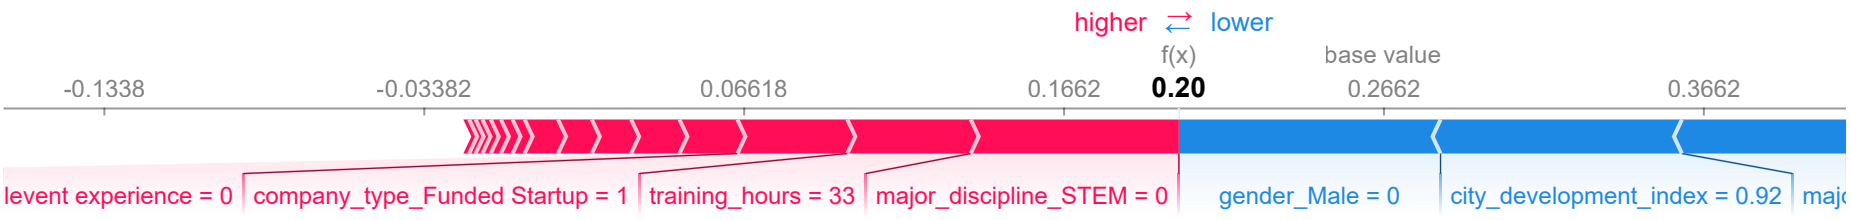

По графику можно увидеть, что сильнее всего вероятность ухода из компании данного человека (наблюдения) уменьшается факторами:

- Развитый город места работы (индекс развития города 0.92),
- Не-мужской пол специалиста,
- Специализация в гуманитарных науках.

Что интересно, повышают вероятность ухода следующие факторы:

- Специализация не в STEM науках,
- 33 часа обучения на рабочем месте,
- Работа в стартапе.